

期末考试范围

- 期末考试范围：第一章到第八章（第十二章不考，但作业需要做）
- 重点章节：第二，第三，第四，第七，第八章
- 重点概念题：全概率公式，随机变量函数的分布，独立性，边缘分布，两个随机变量函数分布，协方差，相关系数，参数估计，假设检验，区间估计

常用公式&结论

$$P(AB) + P(A\bar{B}) = P(A)$$

常用符号的定义

对任意实数 a 以及非负整数 r ，定义

$$\binom{a}{r} = \frac{a(a-1)\dots(a-r+1)}{r!}, \quad \binom{a}{0} = 1$$

特别的，当 a 为正整数，且 $r \leq a$ 时，该式表示组合数，即有：

$$\binom{a}{r} = C_a^r$$

排列组合

$$A_n^m = n(n-1)(n-2)\cdots(n-m+1) = \frac{n!}{(n-m)!}$$

$$C_n^m = \frac{n!}{m!(n-m)!}$$

抽签原理

中签概率与抽签顺序无关。 n 个人不放回地先后从 n 个签中抽1张，其中 m 张中奖 $(m < n)$ ，则每个人中奖的概率均为 $P = \frac{m}{n}$ 。

概率论的基本概念

事件的运算

- 若事件 A 、 B 互斥，则 $P(AB) = 0$ ，反之不成立

交换律

$$A \cup B = B \cup A, \quad A \cap B = B \cap A$$

结合律

$$A \cup (B \cup C) = (A \cup B) \cup C$$

$$A \cap (B \cap C) = (A \cap B) \cap C$$

分配律

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$$

$$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$$

德摩根律

$$\overline{A \cup B} = \overline{A} \cap \overline{B}$$

$$\overline{A \cap B} = \overline{A} \cup \overline{B}$$

概率

概率的定义 (条件)

非负性

对于每一个事件 A , 有 $P(A) \geq 0$

规范性

对于必然事件 S , 有 $P(S) = 1$

可列可加性

设 A_1, A_2, \dots 是两两互不相容的事件, 即对于 $A_i A_j = \emptyset, i \neq j, i, j = 1, 2, \dots$ 有:

$$P(A_1 \cup A_2 \cup \dots) = P(A_1) + P(A_2) + \dots$$

概率的重要性质

性质1

$$P(\emptyset) = 0$$

性质2 (有限可加性)

若 A_1, A_2, \dots, A_n 是两两互不相容的事件，则有：

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = P(A_1) + P(A_2) + \dots + P(A_n)$$

性质3

若事件 A, B 满足 $A \subset B$ ，则有：

$$\begin{aligned} P(B - A) &= P(B) - P(A) \\ P(B) &\geq P(A) \end{aligned}$$

性质4

对任一事件A有：

$$P(A) \leq 1$$

性质5 (逆事件的概率)

$$P(\overline{A}) = 1 - P(A)$$

性质6 (加法公式)

对任意两事件A, B有：

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

古典概型

古典概型的特点：

1. 试验的样本空间只包含有限个元素
2. 试验中每个基本事件发生的可能性相同

古典概型事件概率的计算公式

若事件A包含k个基本事件，即 $A = \{e_{i_1}\} \cup \{e_{i_2}\} \cup \dots \cup \{e_{i_k}\}$ ，这里 i_1, i_2, \dots, i_n 是 $1, 2, \dots, n$ 中某k个不同的数，则有：

$$P(A) = \sum_{j=1}^k P(\{e_{i_j}\}) = \frac{k}{n} = \frac{A\text{包含的基本事件数}}{S\text{中基本事件的总数}}$$

条件概率

定义

设A, B是两个事件, 且 $P(A) > 0$, 称

$$P(B|A) = \frac{P(AB)}{P(A)}$$

为在事件A发生的条件下事件B发生的条件概率。

条件概率满足的条件

非负性

对每一事件B, 有 $P(B|A) \geq 0$

规范性

对于必然事件S, 有 $P(S|A) = 1$

可列可加性

设 B_1, B_2, \dots 是两两互不相容的事件, 则有:

$$P\left(\bigcup_{i=1}^{\infty} B_i | A\right) = \sum_{i=1}^{\infty} P(B_i | A)$$

乘法定理

设 $P(A) > 0$, 有:

$$P(AB) = P(B|A)P(A)$$

上式称为**乘法公式**

乘法公式的推广

设A, B, C为事件, 且 $P(AB) > 0$, 则有:

$$P(ABC) = P(C|AB)P(B|A)P(A)$$

一般的, 设 A_1, A_2, \dots, A_n 为n个事件, $n \geq 2$, 且 $P(A_1 A_2 \dots A_{n-1}) > 0$, 则有

$$P(A_1 A_2 \dots A_n) = P(A_n | A_1 A_2 \dots A_{n-1})P(A_{n-1} | A_1 A_2 \dots A_{n-2}) \dots P(A_2 | A_1)P(A_1)$$

全概率公式 **重点**

设试验E的样本空间为S, A为E的事件, B_1, B_2, \dots, B_n 为S的一个划分, 且 $P(B_i) > 0$, ($i = 1, 2, \dots, n$), 则:

$$\begin{aligned} P(A) &= P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n) \\ &= \sum_{i=1}^n P(A|B_i)P(B_i) \end{aligned}$$

贝叶斯公式 重点

设试验E的样本空间为S, A为E的事件, B_1, B_2, \dots, B_n 为S的一个划分, 且 $P(A) > 0, P(B_i) > 0 (i = 1, 2, \dots, n)$, 则:

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

事实上有:

$$P(B_i|A) = \frac{P(AB_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

(利用全概率公式)

注 贝叶斯公式可用于“已知结果判断原因”的情况

随机变量及其分布 重点

分布函数

定义 设 ξ 是随机变量, x 是任意的实数, 称

$$F(x) = P(\xi \leq x) \quad (-\infty < x < \infty)$$

为随机变量 ξ 的**分布函数**

注意

- $F(x)$ 是随机变量 ξ 取值不大于 x 的概率, 即分布函数 $F(x)$ 描述的是事件 $\xi \leq x$ 的概率, 它是**定义于全体实数, 以区间[0, 1]为值域**的普通函数
- 对任意实数 $a < b$, 随机点落在区间 $(a, b]$ 内的概率, 显然有

$$P(a < \xi \leq b) = P(\xi \leq b) - P(\xi \leq a) = F(b) - F(a)$$

分布函数的性质

- $0 \leq F(x) \leq 1$
- 若 $x_1 < x_2$, 则 $F(x_1) \leq F(x_2)$, 即 $F(x)$ 是**不减函数**
- $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, \quad F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1$

- $F(x_0 + 0) = \lim_{t \rightarrow x_0^+} F(t) = F(x_0)$

即 $F(x)$ 是右连续的.

进一步还可以得到其他性质:

- $P(\xi > x) = 1 - P(\xi \leq x) = 1 - F(x)$
- $P(\xi = x) = F(x) - F(x - 0)$
- $P(\xi < x) = P(\xi \leq x) - P(\xi = x) = F(x - 0)$
- $P(\xi \geq x) = 1 - P(\xi < x) = 1 - F(x - 0)$

离散型随机变量及其分布

离散型随机变量: 随机变量的所有可能取值是有限多个或可列无限多个

分布列

设 ξ 是一个离散型随机变量, 取值为 $x_1, x_2, \dots, x_n, \dots$, 且


$P(\xi = x_k) = p_k (k = 1, 2, \dots)$, 则称 $\{p_k\}$ 为随机变量 ξ 的概率分布列, 简称分布列.

根据概率的性质, 分布列满足:

- $p_k \geq 0, k = 1, 2, \dots$
- $\sum_{k=1}^{\infty} p_k = 1$

离散型随机变量的分布函数

- (1) $F(x)$ 是不减的阶梯函数;
- (2) 其间断点均为右连续的;
- (3) 其间断点即为 X 的可能取值点;
- (4) 其间断点的跳跃高度是对应的概率值.



常见的离散型随机变量

(0-1) 分布 (伯努利分布、两点分布)

随机变量 X 只可能取0、1两个值，其分布列为：

$$P(X = k) = p^k(1 - p)^{1-k}$$
$$k = 0, 1 \quad (0 < p < 1)$$

二项分布

若试验 E 只有两种可能结果A和它的逆事件 \bar{A} ，则称 E 为伯努利试验.

设随机变量 ξ 表示 n 重伯努利试验中“成功”出现的次数，设每次成功的概率为 p ，则 ξ 的分布列为：

$$p_k = P(\xi = k) = C_n^k p^k (1 - p)^{n-k}$$
$$(k = 0, 1, \dots, n; 0 < p < 1)$$

称 ξ 服从二项分布，记为：

$$\xi \sim b(n, p)$$

泊松分布

设随机变量 X 取值 $0, 1, 2, \dots$ ，且其分布列为：

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!} \quad k = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 是常数

则称 X 服从参数为 λ 的泊松分布，记作：

$$X \sim \pi(\lambda)$$

泊松定理

设随机变量 X 服从二项分布 $B(n, p_n)$ ，又设 $\lambda > 0$ 是一常数， n 是任意正整数，若 $np_n = \lambda$ ，则对任一固定的非负整数 k 有：

$$\lim_{n \rightarrow \infty} P_n(X = k) = \lim_{n \rightarrow \infty} C_n^k p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k e^{-\lambda}}{k!}$$

上述定理表明当 n 很大， p 很小($np = \lambda$)时有以下近似式：

$$C_n^k p^k (1 - p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!} \quad (\text{其中 } \lambda = np)$$

即以 n, p 为参数的二项分布的概率值可以由参数为 $\lambda = np$ 的泊松分布的概率值近似.

连续型随机变量及其分布

定义 对于随机变量X的分布函数 $F(x)$, 如果存在非负可积函数 $f(x), x \in (-\infty, +\infty)$, 使得对任意实数x, 有

$$F(x) = \int_{-\infty}^x f(t)dt = P(X \leq x)$$

则称X为**连续型随机变量**, 称 $f(x)$ 为X的概率密度函数, 简称为**概率密度**.

注

- 连续型随机变量的分布函数在R上连续
- 连续型随机变量取任一指定实数值a的概率均为0, 即:

$$P(X = a) = 0$$

- 对连续型随机变量X, 有:

$$\begin{aligned} P(a \leq X \leq b) &= P(a < X \leq b) \\ &= P(a \leq X < b) \\ &= P(a < X < b) \end{aligned}$$

概率密度的性质

- $f(x) \geq 0$
- $\int_{-\infty}^{+\infty} f(x)dx = 1$

上述两条性质是判定一个 $f(x)$ 是**某随机变量X的概率密度**的充要条件.

- 对于任意实数 $x_1, x_2 (x_1 < x_2)$:

$$P\{x_1 < X \leq x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(x)dx$$

- 若 $f(x)$ 在点x处连续, 则有:

$$F'(x) = f(x)$$

常见的连续型随机变量

均匀分布

若随机变量X的概率密度为:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他} \end{cases}$$

则称X在区间(a, b)上服从均匀分布, 记作

$$X \sim U(a, b)$$

X的分布函数为

$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x < b \\ 1, & x \geq b \end{cases}$$

指数分布

若随机变量X具有概率密度:

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad \text{其中 } \theta > 0 \text{ 为常数}$$

则称X服从参数为θ的指数分布, 其分布函数为:

$$F(x) = \begin{cases} 1 - e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

说明 $E(X) = \theta$

性质

无记忆性

$$P\{X > x_0 + \Delta x | X > x_0\} = P\{X > \Delta x\}$$

证明:

$$\begin{aligned} P\{X > x_0 + \Delta x | X > x_0\} &= \frac{P\{(X > x_0 + \Delta x) \cap (X > x_0)\}}{P\{X > x_0\}} \\ &= \frac{P\{X > x_0 + \Delta x\}}{P\{X > x_0\}} = \frac{e^{-\frac{x_0+\Delta x}{\theta}}}{e^{-\frac{x_0}{\theta}}} = P\{X > \Delta x\} \end{aligned}$$

另注

- 指数分布: 唯一无记忆性的连续型分布
- 几何分布: 唯一无记忆性的离散型分布

正态分布

若连续型随机变量 X 的概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty$$

其中 μ 和 $\sigma(\sigma > 0)$ 都是常数



则称 X 服从参数为 μ 和 σ 的正态分布或高斯分布，记作

$$X \sim N(\mu, \sigma^2)$$

正态分布概率密度函数 $f(x)$ 的性质

概率密度函数 $f(x)$ 的性质

- (1) $f(x)$ 关于直线 $x = \mu$ 对称.
在 $x = \mu$ 点 $f(x)$ 取得最大值.
- (2) 曲线以 x 轴为渐近线.
- (3) 若 σ 固定, μ 改变,
 $f(x)$ 左右移动,
形状保持不变.
- (4) 若 μ 固定, σ 改变,
 σ 越大曲线越平坦;
 σ 越小曲线越陡峭.




标准正态分布

当 $\mu = 0, \sigma = 1$ 时, $N(0, 1)$ 称为[标准正态分布](#)

概率密度函数: $\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < \infty$

分布函数: $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt, \quad -\infty < x < \infty$

标准正态分布 $\varphi(x)$ 和 $\Phi(x)$ 图形如下



$\varphi(x), \Phi(x)$ 的性质

- $\varphi(0) = \frac{1}{\sqrt{2\pi}}$, $\Phi(0) = \frac{1}{2}$
- $\varphi(-x) = \varphi(x)$
- $\Phi(-x) = 1 - \Phi(x)$
- 若正态分布 $N(\mu, \sigma^2)$ 的分布函数为 $F(x)$, 则

$$F(x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

该性质表明, 可以用标准正态分布的分布函数 $\Phi(x)$ 计算其他正态分布的分布函数 $F(x)$.

进而可以得到, 若 $X \sim N(\mu, \sigma^2)$, 则

$$\begin{aligned} F(x) &= P\left\{\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right\} = \Phi\left(\frac{x - \mu}{\sigma}\right) \\ P\{x_1 < X \leq x_2\} &= F(x_2) - F(x_1) = \Phi\left(\frac{x_2 - \mu}{\sigma}\right) - \Phi\left(\frac{x_1 - \mu}{\sigma}\right) \end{aligned}$$

$\Phi(x)$ 的计算

➤ $x \geq 0$ 时, 查标准正态分布函数表.

➤ $x < 0$ 时, 用 $\Phi(x) = 1 - \Phi(-x)$.

若 $X \sim N(0, 1)$, 则

- (1) $P(X \leq a) = \Phi(a);$
- (2) $P(X > a) = 1 - \Phi(a);$
- (3) $P(a < X < b) = \Phi(b) - \Phi(a);$
- (4) 若 $a \geq 0$, 则

$$\begin{aligned} P(|X| < a) &= P(-a < X < a) = \Phi(a) - \Phi(-a) \\ &= \Phi(a) - [1 - \Phi(a)] = 2\Phi(a) - 1 \end{aligned}$$

3 σ 规则

当 $X \sim N(0, 1)$ 时

$$P(|X| \leq 1) = 0.6826$$

$$P(|X| \leq 2) = 0.9544$$

$$P(|X| \leq 3) = 0.9974$$

当 $X \sim N(\mu, \sigma^2)$ 时

$$P(|X - \mu| \leq \sigma) = 0.6826$$

$$P(|X - \mu| \leq 2\sigma) = 0.9544$$

$$P(|X - \mu| \leq 3\sigma) = 0.9974$$

离散型和连续型随机变量的比较

离散型	连续型
1. 分布列: $p_n = P(X=x_n)$ (唯一)	1. 密度函数 $X \sim f(x)$ (不唯一)
2. $F(x) = \sum_{x_i \leq x} P(X = x_i)$	2. $F(x) = \int_{-\infty}^x f(t)dt$
3. $F(a+0) = F(a); \quad P(a < X \leq b) = F(b) - F(a).$	
4. 点点计较	4. $P(X=a) = 0$
5. $F(x)$ 为阶梯函数。 $F(a-0) \neq F(a).$	5. $F(x)$ 为连续函数。 $F(a-0) = F(a).$

随机变量函数的分布 重点

若 $X \sim N(\mu, \sigma^2)$, 令 $Y = \frac{X-\mu}{\sigma}$, 则 $Y \sim N(0, 1)$.

X为连续型随机变量

若X为连续型随机变量, 概率密度为 $f_X(x)$, 求 $Y = g(X)$ 的概率密度 $f_Y(x)$ 一般采用[分布函数法](#):

1. 分布函数法

第一步：由 X 的分布函数求出 Y 的分布函数表达式

$$F_Y(y) = P\{Y \leq y\} = P\{g(X) \leq y\} = P\{X \in C_y\}$$

$$\text{其中 } C_y = \{x \mid g(x) \leq y\}$$

第二步：对分布函数求导数即得所求概率密度.

多维随机变量及其分布 重点

边缘分布 重点

- 离散型

$$P\{X = x_i\} = \sum_{j=1}^{\infty} p_{ij} = p_{i\cdot}$$

$$P\{Y = y_j\} = \sum_{i=1}^{\infty} p_{ij} = p_{\cdot j}$$

称 $p_{i\cdot}, p_{\cdot j}$ 为边缘分布律

- 连续型

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

$$f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

称 $f_X(x), f_Y(y)$ 为边缘概率密度

条件分布

###

相互独立的随机变量 重点

若随机变量 X, Y 相互独立，其等价条件为：

$$F(x, y) = F_X(x)F_Y(y)$$

- 若连续型随机变量 X, Y 相互独立，其等价条件为：

$$f(x, y) = f_X(x)f_Y(y)$$

- 若离散型随机变量 X, Y 相互独立，其等价条件为：

$$P\{X = x_i, Y = y_j\} = P\{X = x_i\}P\{Y = y_j\}$$

两个随机变量的函数的分布 重点

$Z = X + Y$ 的分布

设 (X, Y) 是二维连续型随机变量，它具有概率密度 $f(x, y)$ ，则 $Z = X + Y$ 仍为连续型随机变量，其概率密度为：

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(z - y, y) dy$$

或 $f_{X+Y}(z) = \int_{-\infty}^{\infty} f(x, z - x) dx$

若 X, Y 相互独立，设 (X, Y) 关于 X, Y 的边缘密度分别为 $f_X(x), f_Y(y)$ ，则上式可化为：

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f_X(z - y)f_Y(y) dy$$

或 $f_{X+Y}(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x) dx$

上两式称为 f_X, f_Y 的 [卷积公式](#)

正态随机变量的线性组合

设 X, Y 相互独立且 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ ，则有：

$$Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$
$$aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$$

更一般地，可以证明 [有限个相互独立的正态随机变量的线性组合仍然服从正态分布。](#)

$M = \max\{X, Y\}$ 及 $N = \min\{X, Y\}$ 的分布 常考

- $M = \max\{X, Y\}$ 的分布函数为：

$$F_{\max}(z) = F_X(z)F_Y(z)$$

- $N = \min\{X, Y\}$ 的分布函数为：

$$F_{\min}(z) = 1 - [1 - F_X(z)][1 - F_Y(z)]$$

随机变量的数字特征 重点

常用分布的数字特征总结

常用分布	分布律 / 概率密度	期望	方差
两点分布	$P(X=k) = p^k(1-p)^{1-k} \quad k=0,1$	p	pq
二项分布 $B(n, p)$	$P(X=k) = C_n^k p^k (1-p)^{n-k} \quad k=0,1,\dots,n$	np	npq
泊松分布 $P(\lambda)$	$P(X=k) = \frac{\lambda^k e^{-\lambda}}{k!} \quad k=0,1,\dots$	λ	λ
均匀分布 $U(a,b)$	$f(x) = \begin{cases} 1/(b-a), & a < x < b \\ 0, & \text{其它} \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布	$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0 \\ 0, & \text{其它} \end{cases}$	θ	θ^2
正态分布 $N(\mu, \sigma^2)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad -\infty < x < \infty$	μ	σ^2

纠正：

对于二项分布 $B(n, p)$, 其分布律为:

$$P(X=k) = C_n^k p^k (1-p)^{n-k} \quad k=0,1,\dots,n$$

- 两点分布的方差推导:

$$\begin{aligned} E(X^2) &= E(X) = p \\ D(X) &= E(X^2) - E^2(X) = p - p^2 = p(1-p) \end{aligned}$$

- 指数分布的分布函数:

$$F(x) = 1 - e^{-\frac{x}{\theta}} \quad (x > 0)$$

数学期望

数学期望简称期望, 又称均值

离散型随机变量的数学期望

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

(级数绝对收敛)

连续型随机变量的数学期望

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

(积分绝对收敛)

随机变量函数的数学期望

设随机变量Y是随机变量X的函数: $Y = g(X)$ (连续函数)

- X为离散型随机变量

$$E(Y) = E[g(X)] = \sum_{k=1}^{\infty} g(x_k) p_k$$

- X为连续型随机变量

$$E(Y) = E[g(X)] = \int_{-\infty}^{+\infty} g(x) f(x) dx$$

多随机变量函数的数学期望

离散型

定理 设 $g(X, Y)$ 为二元连续函数,

(1) 若 (X, Y) 是离散型, $P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$,

且级数 $\sum_i \sum_j g(x_i, y_j) p_{ij}$ 绝对收敛, 则

$$E[g(X, Y)] = \sum_i \sum_j g(x_i, y_j) p_{ij}$$

(2) 若 (X, Y) 是连续型, 其概率密度为 $f(x, y)$,

且级数 $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$ 绝对收敛, 则

$$E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$$

连续型

设 Z 是随机变量 X, Y 的函数: $Z = g(X, Y)$ (连续函数), 若二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, 则有

$$E(Z) = E[g(X, Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) dx dy$$

特别的, 令 $Z = X$, 则有:

$$E(X) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x f(x, y) dx dy$$

由 (X, Y) 联合分布律或联合概率密度求 X, Y 的数学期望

对于二维随机变量 (X, Y) , 若 $E(X), E(Y)$ 都存在

(1) 若 (X, Y) 是离散型, $P\{X = x_i, Y = y_j\} = p_{ij}, i, j = 1, 2, \dots$,

$$\text{则 } E(X) = \sum_i x_i p_{i.} = \sum_i \sum_j x_i p_{ij}$$

$$E(Y) = \sum_j y_j p_{.j} = \sum_j \sum_i y_j p_{ij}$$

(2) 若 (X, Y) 是连续型, 其概率密度为 $f(x, y)$,

$$\text{则 } E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f(x, y) dx dy$$

$$E(Y) = \int_{-\infty}^{+\infty} y f_Y(y) dy = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f(x, y) dx dy$$

条件数学期望

- 离散型

$$E(X|Y = y_j) = \sum x_i p_{i|j}$$

- 连续型

$$E(X|Y = y) = \int_{-\infty}^{+\infty} x f_{X|Y}(x|y) dx$$

数学期望的性质

- $E(C) = C$
- $E(CX) = CE(X)$

- $E(X \pm Y) = E(X) \pm E(Y)$

- 设 X, Y 相互独立，则

$$E(XY) = E(X)E(Y)$$

注意 该结论反之不一定成立

方差

$$D(X) = Var(X) = E\{[X - E(X)]^2\}$$

定义 设 X 是一个随机变量，若 $E[(X-E(X))^2]$ 存在，称 $E[(X-E(X))^2]$ 为 X 的方差。记为 $D(X)$ 或 $Var(X)$ ，即

$$D(X) = Var(X) = E[X - E(X)]^2$$

方差的算术平方根 $\sqrt{D(X)}$ 称为 X 的标准差或均方差，记为 $\sigma(X)$ 。

方差的计算

方差 $D(X)$ 可以看做随机变量 X 的函数 $g(X) = [X - E(X)]^2$ 的数学期望

1) X 为离散型，分布律为 $P\{X=x_k\}=p_k$

$$D(X) = \sum_k [x_k - E(X)]^2 p_k$$

2) X 为连续型，概率密度 $f(x)$

$$D(X) = \int_{-\infty}^{+\infty} [x - E(X)]^2 f(x) dx$$

计算方差的简化公式：

$$D(X) = E(X^2) - E^2(X)$$

方差的性质

设 $D(X), D(Y)$ 都存在， C 为常数

$$(1) \quad D(C) = 0$$

$$(2) \quad D(CX) = C^2 D(X)$$

$$(3) \quad D(X + Y) = D(X) + D(Y) + 2E[X - E(X)][Y - E(Y)]$$

特别，若 X, Y 相互独立，则 $D(X + Y) = D(X) + D(Y)$

$$(4) \quad D(X) = 0 \text{ 的充要条件是 } P\{X = E(X)\} = 1$$

对于(3)有：

$$D(X + Y) = D(X) + D(Y) + 2Cov(X, Y)$$

当 X, Y 不相关时， $Cov(X, Y) = 0$ ，则有 $D(X + Y) = D(X) + D(Y)$

协方差与相关系数 重点

协方差

定义 设 X 和 Y 为两随机变量，若 $E\{[X - E(X)][Y - E(Y)]\}$ 存在，则称之为随机变量 X 和 Y 的协方差，记为 $Cov(X, Y)$ 或 σ_{XY} ，即

$$\sigma_{XY} = Cov(X, Y) = E[X - E(X)][Y - E(Y)]$$

(1) 若 (X, Y) 为离散型， $P\{X = x_i, Y = y_j\} = p_{ij}$ ，则

$$Cov(X, Y) = \sum_{i,j} [x_i - E(X)][y_j - E(Y)]p_{ij}$$

(2) 若 (X, Y) 为连续型，其概率密度为 $f(x, y)$ ，则

$$Cov(X, Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} [x - E(X)][y - E(Y)]f(x, y) dx dy$$

[计算协方差的简单公式](#)：

$$Cov(X, Y) = E(XY) - E(X)E(Y)$$

特别地，当 $X=Y$ 时，

$$Cov(X, X) = E(X^2) - E^2(X) = D(X)$$

可见方差可看作协方差的一个特例，并且有

$$D(X+Y) = D(X) + D(Y) + 2Cov(X, Y)$$

协方差的性质

协方差的性质：

(1) $Cov(X, Y) = Cov(Y, X)$

(2) $Cov(aX, bY) = abCov(X, Y)$ 其中 a, b 为常数

(3) $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$

(4) 若 X 与 Y 独立，则 $Cov(X, Y) = 0$

相关系数

定义： 设 $D(X) > 0, D(Y) > 0$ ，称

$$\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)} \sqrt{D(Y)}}$$

为随机变量 X 和 Y 的相关系数。

也可表示为

$$\rho_{XY} = \frac{\sigma_{XY}}{\sqrt{\sigma_{XX}} \sqrt{\sigma_{YY}}}$$

相关系数的性质

- $|\rho_{XY}| \leq 1$
- $|\rho_{XY}| = 1 \iff \text{存在常数 } a, b, \text{使得 } P\{Y = aX + b\} = 1$

说明

(1) 相关系数 ρ_{XY} 刻画了随机变量 Y 与 X 之间的“线性相关”程度: $|\rho_{XY}|$ 的值越接近于 1, Y 与 X 的线性相关程度越高; $|\rho_{XY}|$ 的值越接近于 0, Y 与 X 的线性相关程度较弱.

当 $|\rho_{XY}| = 1$, 称 X 与 Y 完全线性相关;

当 $\rho_{XY} = 0$, 称 X 与 Y 不相关;

(2) 当 $\rho_{XY}=0$ 时, 只说明 Y 与 X 之间没有线性关系, 并不能说明 Y 与 X 之间没有其他函数关系, 从而不能推出 Y 与 X 独立.

对“不相关性”和“相互独立”区别的说明

对随机变量 X, Y , 有如下事实等价:

- 1、 $Cov(X, Y)=0$;
- 2、 X 与 Y 不相关;
- 3、 $E(XY)=E(X)E(Y)$;
- 4、 $D(X+Y)=D(X)+D(Y)$.

注意相互独立与不相关性是不同的两个概念, 独立性比不相关性的要求更强.

性质 如果随机变量 X 与 Y 互相独立, 则 X 与 Y 不相关。
(反之不成立)



特例 二维正态随机变量 X 与 Y 相互独立与不相关是等价的

矩和协方差矩阵

原点矩&中心矩

定义 设 X 和 Y 是随机变量, k, l 为正整数,

若以下期望存在, 称

$E(X^k)$ 为 X 的 **k 阶原点矩**(简称 **k 阶矩**)

$E\{[X - E(X)]^k\}$ 为 X 的 **k 阶中心矩**

$E(X^k Y^l)$ 为 X 和 Y 的 **$k+l$ 阶混合矩**;

$E\{[X - E(X)]^k [Y - E(Y)]^l\}$ 为 X 和 Y 的 **$k+l$ 阶混合中心矩**

显然, $E(X)$ 是 X 的一阶原点矩, $D(X)$ 是 X 的二阶中心矩,
 $\text{Cov}(X, Y)$ 是 X 和 Y 的二阶混合中心矩.

协方差矩阵

定义 设 n 维随机变量 (X_1, X_2, \dots, X_n) 的二阶混合中心矩

$$\sigma_{ij} = \text{Cov}(X_i, X_j) = E[X_i - E(X_i)][X_j - E(X_j)] \quad (i, j=1, 2, \dots, n)$$

都存在, 则称矩阵

$$B = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1n} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} & \sigma_{n2} & \cdots & \sigma_{nn} \end{pmatrix}$$

为 n 维随机变量 (X_1, X_2, \dots, X_n) 的 **协方差矩阵**, 记为 B .

显然协方差矩阵的元素为方差和协方差, 且 $B^T = B$.

相关矩阵

若令 $\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}}\sqrt{\sigma_{jj}}}$, 则 ρ_{ij} 是 X_i 和 X_j 的相关系数,

此时称矩阵

$$R = \begin{pmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1n} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{n1} & \rho_{n2} & \cdots & \rho_{nn} \end{pmatrix}$$

为 n 维随机变量 (X_1, X_2, \dots, X_n) 的 **相关矩阵**, 记为 R .

大数定律与中心极限定理

大数定律

切比雪夫不等式

设 X 为随机变量, $E(X) = \mu$, $D(X) = \sigma^2 < +\infty$, 则对任意的正数 ε , 有

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$$

等价于:

$$P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$$

说明

- 切比雪夫不等式只与随机变量 X 的期望和方差有关, 与 X 的分布类型无关
- 切比雪夫不等式给出了随机变量偏离期望的概率的下界, 但通常该下界比较“保守”

三个常用的大数定律

依概率收敛:

定义 设 $X_1, X_2, \dots, X_n, \dots$ 是随机变量序列， A 是常数。若对任意 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\{|X_n - A| < \varepsilon\} = 1$$

则称 $X_1, X_2, \dots, X_n, \dots$ 依概率收敛于 A ，记为 $X_n \xrightarrow{P} A$ 。

注： 依概率收敛表示当 n 无限增大时，对任意 $\varepsilon > 0$ ，事件 $\{|X_n - A| < \varepsilon\}$ 发生的概率无限接近于 1。但不排除事件 $\{|X_n - A| \geq \varepsilon\}$ 发生，只是发生的可能性很小。

切比雪夫大数定律

定理 设 $X_1, X_2, \dots, X_n, \dots$ 是相互独立随机变量序列， l 是正常数，且 $E(X_i) = \mu_i < +\infty$, $D(X_i) \leq l < +\infty$ ($i=1, 2, \dots$)，则对任意的 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow +\infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n \mu_i\right| < \varepsilon\right\} = 1$$

辛钦大数定律

设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立，服从同一分布，且 $E(X_k) = \mu$, ($k=1, 2, \dots$)，作前 n 个随机变量的算术平均

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k,$$

则对于任意正数 ε ，有

$$\lim_{n \rightarrow \infty} P\{|\bar{X} - \mu| < \varepsilon\} = \lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{k=1}^n X_k - \mu\right| < \varepsilon\right\} = 1.$$

说明

- 切比雪夫大数定律里随机变量序列不要求是同分布的，但是要求它们的方差有一致的上界。
- 辛钦大数定律里随机变量序列要求是同分布的，但不要求它们的方差存在或有一致上界。

伯努利大数定律

设 n 次独立重复试验中事件 A 发生的次数为 n_A ，
事件 A 在每次试验中发生的概率是 $p(0 < p < 1)$ ，则对于任意正数 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\left\{ \left| \frac{n_A}{n} - p \right| < \varepsilon \right\} = 1$$

说明

伯努利大数定律表明事件发生的频率 $\frac{n_A}{n}$ 依概率收敛于事件的概率 p .

这个定理以严格的数学形式表达了频率的稳定性. 就是说 n 很大时，事件发生的频率与概率有较大偏差的可能性很小. 由实际推断原理，在实际应用中，当试验次数很大时，便可以用事件发生的频率来代替事件的概率.

中心极限定理

中心极限定理：随机变量和的分布收敛于正态分布的一类定理

三个常用的中心极限定理

独立同分布中心极限定理

定理 设随机变量 $X_1, X_2, \dots, X_n, \dots$ 相互独立，服从同一分布，且 $E(X_k) = \mu$, $D(X_k) = \sigma^2 \neq 0$ ($k=1, 2, \dots$)，则

$$\lim_{n \rightarrow \infty} P\left\{ \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt = \Phi(x)$$

也就是说当 n 充分大时，

$$Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} = \frac{\frac{1}{n} \sum_{k=1}^n X_k - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \text{ 近似服从标准正态分布}$$

说明

1) 定理表明，独立同分布的随机变量之和 $\sum_{k=1}^n X_k$ ，当 n 充分大时，随机变量之和与其标准化变量分别有

$$\sum_{k=1}^n X_k \xrightarrow{\text{近似地}} N(n\mu, n\sigma^2), \quad \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \xrightarrow{\text{近似地}} N(0,1).$$

2) 独立同分布中心极限定理的另一种形式可写为

$$\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{\text{近似地}} N(\mu, \sigma^2/n) \text{ 或 } \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{\text{近似地}} N(0,1).$$

李雅普诺夫中心极限定理

定理 设 $X_1, X_2, \dots, X_n, \dots$ 是相互独立随机变量序列，且 $E(X_i) = \mu_i, D(X_i) = \sigma_i^2 (i=1,2, \dots)$ ，令 $B_n^2 = \sum_{i=1}^n \sigma_i^2$ ，若存在 $\delta > 0$ ，使得

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E |X_i - \mu_i|^{2+\delta} = 0,$$

则对任意实数 x ，有

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\{Z_n \leq x\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

其中 $Z_n = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n} = \frac{\sum_{k=1}^n (X_k - \mu_k)}{B_n}$

德莫弗-拉普拉斯中心极限定理 重点 (参考教材第五版P126, 例1,2,3)

设随机变量 $Y_n \sim B(n, p)$ ，其中 $0 < p < 1, n = 1, 2, \dots$ 则对任意 x ，有

$$\lim_{n \rightarrow \infty} P\left\{ \frac{Y_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

说明

定理表明，正态分布是二项分布的极限分布，事件发生的频数 Y_n 近似服从正态分布 $N(np, npq)$.

$$\text{即 } Y_n \xrightarrow{\text{近似地}} N(np, np(1-p)) \quad \frac{Y_n}{n} \xrightarrow{\text{近似地}} N(p, \frac{pq}{n})$$

样本与抽样分布

基本概念

经验分布函数

定义：设 (x_1, x_2, \dots, x_n) 是总体 X 的一个容量为 n 的样本值. 先将 x_1, x_2, \dots, x_n 按自小到大的次序排列，并重新编号，设为 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. 则经验分布函数 $F_n(x)$ 为

$$F_n(x) = \begin{cases} 0, & \text{若 } x \leq x_{(1)}, \\ \frac{k}{n}, & \text{若 } x_{(k)} < x \leq x_{(k+1)}, \\ 1, & \text{若 } x > x_{(n)}. \end{cases} \quad (k = 1, 2, \dots, n-1)$$

性质

(1) $F_n(x)$ 为不减左连续函数；

(2) $\lim_{x \rightarrow -\infty} F_n(x) = 0, \lim_{x \rightarrow \infty} F_n(x) = 1$

$F_n(X)$ 的值表示在 n 次独立重复试验中事件 “ $X \leq x$ ” 发生的频率。

用样本推断总体

定理 设总体 X 的分布函数为 $F(x)$, 样本分布函数为 $F_n(x)$, 则当 $n \rightarrow \infty$ 时 $F_n(x)$ 依概率收敛于分布函数 $F(x)$, 即

$$P\left\{\lim_{n \rightarrow \infty} \sup_{-\infty < x < \infty} |F_n(x) - F(x)| = 0\right\} = 1.$$

由定理可知, 当 n 充分大时, 总体分布函数 $F(x)$ 可用经验分布函数 $F_n(x)$ 近似代替, 这就是用样本来推断总体的理论依据.

样本数字特征

常用统计量

- 样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- 样本方差

$$\begin{aligned} S^2 &= \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n \bar{X}^2 \right) \end{aligned}$$

注意 分母为 $n - 1$

- 样本标准差

$$S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

- 样本k阶 (原点) 矩

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k = 1, 2, \dots)$$

- 样本k阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k = 1, 2, \dots)$$

总结： 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本，
 (x_1, x_2, \dots, x_n) 是其观察值.

• 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$;

• 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$

• 样本标准差 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$

• 样本 k 阶(原点)矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (k = 1, 2, \dots)$

• 样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (k = 2, 3, \dots)$

计算观察值即用 x_i 代替 X_i

定理 设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 若 $D(X) = \sigma^2$, 则

$$(1) S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right);$$

$$(2) E(S^2) = \sigma^2. \quad (\text{即样本方差的期望等于总体方差})$$

正态总体的抽样分布

U统计量及其分布

设总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 是它的一个样本,
则样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是正态分布的线性组合, 因
此也服从正态分布, 其期望和方差分别为

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = E(X) = \mu,$$

$$D(\bar{X}) = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n D(X_i) = \frac{1}{n} D(X) = \frac{\sigma^2}{n}$$

$$\text{即 } \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

定理 若总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n
是它的一个样本, 则统计量

$$U = \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

称为 U 统计量.

χ^2 统计量及其分布

定义	$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布，记 $\chi^2 \sim \chi^2(n)$ ，其中 X_1, X_2, \dots, X_n 相互独立，且 $X_i \sim N(0,1), (i=1,2,\dots)$
图像	
期望与方差	$E(\chi^2) = n, D(\chi^2) = 2n.$
性质	若 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, X, Y 相互独立，则 $X+Y \sim \chi^2(n_1+n_2)$

性质：

χ^2 分布的性质：

- (1) 设 $\chi^2 \sim \chi^2(n)$, 则 $E(\chi^2) = n, D(\chi^2) = 2n.$
- (2) 当 n 充分大时, $\chi^2(n)$ 近似服从正态分布 $N(n, 2n)$
- (3) 可加性, 设 $\chi_1^2 \sim \chi^2(n_1), \chi_2^2 \sim \chi^2(n_2)$
且 χ_1^2 与 χ_2^2 相互独立, 则有 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$

定理 若总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 是它的一个样本, 则统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

称为 χ^2 统计量。

重要结论 (记忆, 证明不要求)


若总体 $X \sim N(\mu, \sigma^2)$, X_1, X_2, \dots, X_n 是它的一个样本, 则统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

称为 χ^2 统计量

上侧 α 分位数

定义 设 X 是随机变量，对于给定的正数 α ($0 < \alpha < 1$)，称满足 $P\{X > \lambda\} = \alpha$ 的点 λ 为随机变量 X 的分布的上侧 α 分位数，或上侧临界值。称满足 $P\{|X| > \lambda\} = \alpha$ 的点 λ 为随机变量 X 的分布的双侧 α 分位数，或双侧临界值。



注：当 n 充分大时， $\chi_{\alpha}^2(n) \approx \frac{1}{2}(u_{\alpha} + \sqrt{2n-1})^2$


u_{α} 是标准正态分布的上 α 分位点。

T统计量及其分布

定义

设 $X \sim N(0,1)$, $Y \sim \chi^2(n)$, X, Y 相互独立，则称 $T = \frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布，记 $T \sim t(n)$.

图像



性质

当 $n > 45$ 时，有 $T = \frac{X}{\sqrt{Y/n}} \sim N(0,1)$.

T分布的分位点

t分布的分位点

对给定 α ($0 < \alpha < 1$), 称满足 $P\{t > t_\alpha(n)\} = \int_{t_\alpha(n)}^{\infty} f(x)dt = \alpha$

的点 $t_\alpha(n)$ 为 $t(n)$ 分布的上侧 α 分位数.

► 对不同的 α 及 n , t 分布的上侧 α 分位数已制成附表 4.

► $n > 45$ 时, 无表可查, 则可用标准正态分布近似

$$t_\alpha(n) = u_\alpha, n > 45$$

► 由于 t 分布的概率密度函数关于纵轴对称, 因此实际中用得更多的是双侧分位数 $t_{\alpha/2}(n)$, 注意


$$P\{|t(n)| > t_{\alpha/2}(n)\} = \alpha \text{ 等价于 } P\{t(n) > t_{\alpha/2}(n)\} = \alpha / 2$$

F统计量及其分布

定义	设 $U \sim \chi^2(n_1), V \sim \chi^2(n_2)$, U, V 相互独立, 则称 $F = \frac{U/n_1}{V/n_2}$ 服从自由度为 (n_1, n_2) 的 F 分布, 记 $F \sim F(n_1, n_2)$, 其中 n_1 称为第一自由度, n_2 称为第二自由度。
图像	
性质	$F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$.

F分布的上侧 α 分位数

概率密度函数的图形：



对不同的 α 及 n , F 分布上侧 α 分位数 $F_{\alpha}(n_1, n_2)$ 已制成表6.

注意表中只给出了较小的 α 对应的上侧分位数，若 α

较大，可利用
$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$$

正态总体样本均值与样本方差的分布

设 X_1, X_2, \dots, X_n 来自正态总体 $X \sim N(\mu, \sigma^2)$, \bar{X} 表示样本均值, S^2 表示样本方差, 则近似有:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

扩展 若 $E(X) = \mu$, $D(X) = \sigma^2$, 实际上有:

$$E(\bar{X}) = \mu$$
$$D(\bar{X}) = \frac{\sigma^2}{n}$$

Γ 函数

补充知识：伽玛函数 $\Gamma(\alpha)$

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx \quad \text{或} \quad \Gamma(\alpha) = 2 \int_0^{+\infty} x^{2\alpha-1} e^{-x^2} dx$$

作用：用来快速计算类似伽玛函数的积分

方法： $\Gamma(1) = \int_0^{+\infty} e^{-x} dx = 1 \quad \Gamma\left(\frac{1}{2}\right) = 2 \int_0^{+\infty} e^{-x^2} dx = \sqrt{\pi}$

$$\Gamma(s+1) = s\Gamma(s) \quad \Gamma(n) = (n-1)!$$

例如， $\int_0^{+\infty} x^2 e^{-x} dx = \int_0^{+\infty} x^{3-1} e^{-x} dx = \Gamma(3) = 2$

$$\int_{-\infty}^{+\infty} x^2 e^{-x^2} dx = 2 \int_0^{+\infty} x^{2 \times \frac{3}{2}-1} e^{-x^2} dx = \Gamma\left(\frac{3}{2}\right) = \frac{1}{2} \Gamma\left(\frac{1}{2}\right) = \frac{\sqrt{\pi}}{2}$$

参数估计 重点

点估计

点估计：构造合适的统计量，估计总体的未知参数

注意 估计值与估计量的区别

矩估计法

用样本均值估计总体均值：

设样本均值：

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

总体均值为 μ ，总体均值估计量为 $\hat{\mu}$ ，记 $\hat{\mu} = \bar{X}$

计算未知参数 θ 的矩估计套路

1. $\mu = E(X) = g(\theta)$
2. 令 $\mu = g(\theta) = \bar{X}$ ，解得 $\hat{\theta} = h(\bar{X})$ ，称为 θ 的估计量
3. 用样本观测值求出 \bar{X} ，代入 $h(\bar{X})$ ，得到 θ 的估计值

最大似然估计法

一个试验中，得到了一组样本观察值，则有理由相信这个观察值出现的概率最大。因此，考察未知参数 θ 取何值时，这组样本观察值出现的概率最大，那么就用这个值作为 θ 的（最大似然）估计值。

计算未知参数 θ 的最大似然估计套路

1. 写出似然函数（给定样本出现的概率）
2. 对似然函数取对数（方便求导）
3. 求导，令导函数等于0，反解出 θ ，得到的即为 θ 的估计值（如果是估计量则用随机变量表示）

求解极大似然估计的一般步骤：

(1) 由总体的分布写出似然函数 $L(\theta)$ ；

(2) 建立似然方程 $\frac{\partial L(\theta)}{\partial \theta_i} = 0$ 或 $\frac{\partial \ln L(\theta)}{\partial \theta_i} = 0$

(3) 解上述似然方程。

似然估计的性质

如果 $\hat{\theta}$ 为参数 θ 的极大似然估计量，又函数 $g = g(\theta)$ 具有单值反函数，则 $g(\hat{\theta})$ 是 $g(\theta)$ 的极大似然估计量

估计量的评估标准

无偏性

定义 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的估计量, 如果

$$E(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的无偏估计量.

记 $b_n = E(\hat{\theta}) - \theta$, 称 b_n 为估计量 $\hat{\theta}$ 的偏差.

当 $b_n \neq 0$, 称 $\hat{\theta}$ 是 θ 的有偏估计.

若 $\lim_{n \rightarrow \infty} b_n = 0$, 称 $\hat{\theta}$ 是 θ 的渐近无偏估计.

- 不论总体 X 服从什么分布, 当总体 k 阶矩存在时, 样本 k 阶原点矩 A_k 是总体 k 阶原点矩的无偏估计. 特别地, 样本均值 \bar{X} 是总体均值 $E(X)$ 的无偏估计量.

区间估计

定义 设总体 $X \sim F(x; \theta)$, θ 是未知参数, X_1, X_2, \dots, X_n 是来自总体的样本, 对于给定值 α ($0 < \alpha < 1$), 如果存在两个统计量 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$

满足 $P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} \geq 1 - \alpha$

则称随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 是 θ 的置信度为 $1 - \alpha$ 的置信区间, $1 - \alpha$ 为置信水平, $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 分别称为置信下限和置信上限.

评价置信区间好坏标准:

(1) 精度: $\hat{\theta}_2 - \hat{\theta}_1$ 越小越好;

(2) 置信度: 越大越好.

- 区间估计要求根据样本给出未知参数的一个范围, 并保证参数的真值以指定的较大概率属于这个范围. 即以区间的形式给出未知参数的一个范围, 同时还给出此区间包含参数真值的可信程度. 这种形式的估计称为区间估计.
- $1 - \alpha$ 称为置信度或置信水平
- 置信度的理解: 假设 $1 - \alpha = 0.95$, 则经过 100 次抽样得到的 100 个估计区间中约有 95 个包含了真实值. (以总体均值 μ 的估计为例, μ 是确定的一个未知常数 (不会变化), 但每次抽样得到的样本均值 \bar{X} 都在变化)

构造置信区间的一般方法

构造置信区间的基本思想：在点估计的基础上，构造合适的含样本及待估参数的函数 U ，且已知 U 的分布，再根据给定的置信度导出待估参数置信区间。

►一般步骤：

- (1) 明确是哪个参数的置信区间？置信水平 $1-\alpha$ 是？
- (2) 选取未知参数 θ 的某个较优点估计 $\hat{\theta}$ ；
- (3) 构造待估参数 θ 和估计量 $\hat{\theta}$ 的函数 U ，且其分布已知；
- (4) 对给定的置信水平 $1-\alpha$ ，确定常数 c 和 d ，使

$$P\{c < U < d\} = 1 - \alpha$$

- (5) 对上式作恒等变形，化为 $P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha$
则 $(\hat{\theta}_1 - \hat{\theta}_2)$ 就是 θ 的置信水平为 $1-\alpha$ 的置信区间。

注意 σ 表示总体标准差， S 表示样本标准差

单个正态总体参数的置信区间

参数	条件	置信度为 $1-\alpha$ 的 双侧置信区间
μ	σ^2 已知	$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} Z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} Z_{\alpha/2} \right)$
	σ^2 未知	$\left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$
σ^2	μ 未知	$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right)$

均值 μ 的置信区间

- 方差 σ^2 已知

由:

$$\begin{aligned} \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} &\sim N(0, 1) \\ P\left\{ \left| \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \right| < Z_{\alpha/2} \right\} &= 1 - \alpha \end{aligned}$$

则有:

$$P\left\{ \bar{X} - \frac{\sigma}{\sqrt{n}} Z_{\alpha/2} < \mu < \bar{X} + \frac{\sigma}{\sqrt{n}} Z_{\alpha/2} \right\} = 1 - \alpha$$

即置信度为 $1 - \alpha$ 的置信区间为:

$$\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} Z_{\alpha/2} \right)$$

- 方差 σ^2 未知

由：

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$$

$$P\{-t_{\alpha/2}(n-1) < T < t_{\alpha/2}(n-1)\} = 1 - \alpha$$

则有：

$$P\{\bar{X} - \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1) < \mu < \bar{X} + \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\} = 1 - \alpha$$

由此得到 σ^2 未知时， μ 的置信度为 $1 - \alpha$ 的置信区间为：

$$(\bar{X} - \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1))$$

简写为：

$$\left(\bar{X} \pm \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1) \right)$$

方差 σ^2 的置信区间


方差 σ^2 的置信区间(μ 未知)

σ^2 的无偏估计为 S^2 ，由 χ^2 统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$$

左端分布只包含未知参数 σ^2 ，可以用来构造置信区间

$$P\{\chi^2_{1-\alpha/2}(n-1) < \chi^2 < \chi^2_{\alpha/2}(n-1)\} = 1 - \alpha$$



$$\begin{aligned}
 & P\left\{\chi^2_{1-\alpha/2}(n-1) < \chi^2 < \chi^2_{\alpha/2}(n-1)\right\} = 1 - \alpha \\
 \implies & P\left\{\chi^2_{1-\alpha/2}(n-1) < \frac{(n-1)S^2}{\sigma^2} < \chi^2_{\alpha/2}(n-1)\right\} = 1 - \alpha \\
 \implies & P\left\{\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)} < \sigma^2 < \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right\} = 1 - \alpha
 \end{aligned}$$

得到方差 σ^2 的一个置信度为 $1-\alpha$ 的置信区间：

$$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)} \right)$$

注：标准差 σ 的 $1-\alpha$ 置信区间为 $\left(\frac{\sqrt{n-1}S}{\sqrt{\chi^2_{\alpha/2}(n-1)}}, \frac{\sqrt{n-1}S}{\sqrt{\chi^2_{1-\alpha/2}(n-1)}} \right)$

假设检验 重点

假设检验的步骤

3. 假设检验的步骤

(1) 据题意写出原假设 H_0 和备择假设 H_1 ；

(2) 选择检验方法，写出检验统计量及其分布；

(3) 根据给定的显著性水平确定拒绝域；

(4) 计算检验统计量的值，做出推断。

假设检验情况分类

检验参数	条件	原假设与备择假设	检验法及检验统计量	拒绝域
μ	$\sigma^2 = \sigma_0^2$ 已知	$H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$ <small>双边检验</small>	U 检验	$ u \geq u_{\alpha/2}$
		$H_0: \mu \leq \mu_0, H_1: \mu > \mu_0$ <small>单边检验</small>	$U = \frac{\bar{X} - \mu_0}{\sigma_0 / \sqrt{n}} \sim N(0,1)$	$u \geq u_\alpha$
	σ^2 未知	$H_0: \mu \geq \mu_0, H_1: \mu < \mu_0$	T 检验	$u \leq -u_\alpha$
		$H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$ $H_0: \mu \leq \mu_0, H_1: \mu > \mu_0$ $H_0: \mu \geq \mu_0, H_1: \mu < \mu_0$	$T = \frac{\bar{X} - \mu_0}{S / \sqrt{n}} \sim t(n-1)$	$ t \geq t_{\alpha/2}(n-1)$ $t \geq t_\alpha(n-1)$ $t \leq -t_\alpha(n-1)$
σ^2	μ 已知	$H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2$ $H_0: \sigma^2 \leq \sigma_0^2, H_1: \sigma^2 > \sigma_0^2$ $H_0: \sigma^2 \geq \sigma_0^2, H_1: \sigma^2 < \sigma_0^2$	χ^2 检验	$\chi^2 \leq \chi^2_{1-\alpha/2}(n)$ 或 $\chi^2 \geq \chi^2_{\alpha/2}(n)$
			$\chi^2 = \frac{1}{\sigma_0^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$	$\chi^2 \geq \chi^2_\alpha(n)$ $\chi^2 \leq \chi^2_{1-\alpha}(n)$
	μ 未知	$H_0: \sigma^2 = \sigma_0^2, H_1: \sigma^2 \neq \sigma_0^2$ $H_0: \sigma^2 \leq \sigma_0^2, H_1: \sigma^2 > \sigma_0^2$ $H_0: \sigma^2 \geq \sigma_0^2, H_1: \sigma^2 < \sigma_0^2$	χ^2 检验	$\chi^2 \geq \chi^2_{\alpha/2}(n-1)$ 或 $\chi^2 \leq \chi^2_{1-\alpha/2}(n-1)$
			$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1)$	$\chi^2 \geq \chi^2_\alpha(n-1)$ $\chi^2 \leq \chi^2_{1-\alpha}(n-1)$

